




Credit Card Approval Prediction

Carlos Arturo Rodriguez Ayola

CODERHOUSE

Contexto

- En el sector financiero, las **tarjetas de puntuación de crédito** son una herramienta común para el control de riesgos. Analizan la información personal y los datos que envía un solicitante de tarjeta de crédito para predecir la probabilidad de futuros impagos y su comportamiento de endeudamiento. Este análisis ayuda a los bancos a decidir si aprobar una solicitud. Esencialmente, las puntuaciones de crédito son una forma de cuantificar el riesgo de manera objetiva.
- El objetivo de este trabajo será construir un modelo de Machine Learning que permita predecir los ingresos totales anuales de un usuario o de un grupo de usuarios.







Atributos

- ID: Client number
- CODE_GENDER: Gender
- FLAG_OWN_CAR: Is there a car
- FLAG_OWN_REALTY: Is there a property
- CNT_CHILDREN: Number of children
- AMT_INCOME_TOTAL: Annual income
- NAME_INCOME_TYPE: Income category
- NAME_EDUCATION_TYPE: Education level
- NAME_FAMILY_STATUS: Marital status
- NAME_HOUSING_TYPE: Way of living
- DAYS_BIRTH: Birthday Count backwards from current day (0), -1 means yesterday
- DAYS_EMPLOYED: Start date of employment Count backwards from current day(0). If positive, it means the person currently unemployed.
- FLAG_MOBIL: Is there a mobile phone
- FLAG_WORK_PHONE: Is there a work phone
- FLAG_PHONE: Is there a phone
- FLAG_EMAIL: Is there an email
- OCCUPATION_TYPE: Occupation
- CNT_FAM_MEMBERS: Family size

#	Column	Non-Null Count	Dtype
0	ID	438557 non-null	int64
1	CODE_GENDER	438557 non-null	object
2	FLAG_OWN_CAR	438557 non-null	object
3	FLAG_OWN_REALTY	438557 non-null	object
4	CNT_CHILDREN	438557 non-null	int64
5	AMT_INCOME_TOTAL	438557 non-null	float64
6	NAME_INCOME_TYPE	438557 non-null	object
7	NAME_EDUCATION_TYPE	438557 non-null	object
8	NAME_FAMILY_STATUS	438557 non-null	object
9	NAME_HOUSING_TYPE	438557 non-null	object
10	DAYS_BIRTH	438557 non-null	int64
11	DAYS_EMPLOYED	438557 non-null	int64
12	FLAG_MOBIL	438557 non-null	int64
13	FLAG_WORK_PHONE	438557 non-null	int64
14	FLAG_PHONE	438557 non-null	int64
15	FLAG_EMAIL	438557 non-null	int64
16	OCCUPATION_TYPE	304354 non-null	object
17	CNT_FAM_MEMBERS	438557 non-null	float64


dtypes: float64(2), int64(8), object(8)
memory usage: 60.2+ MB

Algunos datos relevantes




Se puede inferir que, hay un número importante de personas trabajando (working), con niveles de educación como mínimo Secundaria (secondary), casados (married), que tienen una casa o apartamento (House/apartment).

Algunos datos relevantes



Hay unos picos de edad al rededor de los 40 años, en donde se encuentran los máximos picos de cantidad de personas por edad.



Los 2 mayores ingresos de la población están en un rango de edad entre los 50 y los 60 años

Modelos De Machine Learning

- Al ser un problema de ML Supervisado utilizaremos la regresión lineal dado que el objetivo de este problema es predecir el valor de ingreso total de las personas en esta BD, AMT_INCOME_TOTAL. El modelo aprende de los datos etiquetados para hacer predicciones cuando ingresen datos nuevos.
- Para cada uno de los modelos se escogió una población de prueba del 30% del tamaño total de la población, el resto para la predicción.
- Se aplicaron 3 modelos:
 - Regresión Lineal
 - Random Forest Regressor
 - Gradient Boosting Regressor

Resultados

Regresión Lineal - Métricas de Regresión:

Error Cuadrático Medio (MSE): 10392441648.065012

Raíz del Error Cuadrático Medio (RMSE): 101943.32566708334

Coefficiente de Determinación (R^2): 0.1287820605860135

Gradient Boosting Regressor - Métricas de Regresión:

Error Cuadrático Medio (MSE): 9649098606.413082

Raíz del Error Cuadrático Medio (RMSE): 98229.82544224072




Coefficiente de Determinación (R^2): 0.1910979065591587

Random Forest Regressor:

Error Cuadrático Medio (MSE): 1029754512.1601466

Coefficiente de Determinación (R^2): 0.9136737414971718

Gráficas de dispersión de los valores reales vs las predicciones para cada uno de los modelos implementados



Conclusiones

Dados los resultados presentados, se selecciona como mejor modelo de regresión a trabajar el **Random Forest**. A seguir las diferencias encontradas con los otros modelos y porqué se seleccionó el Random Forest.

1.Regresión Lineal:

- El modelo presenta un 12.9% de la variabilidad de los ingresos, lo cual es muy bajo.
- El RMSE es bastante alto (101k), lo cual indica que las predicciones tienen un error promedio de ± 101 mil.
- Al parecer los ingresos no presentan una relación lineal fuerte con las variables predictoras.

2.Random Forest

- El modelo presenta un 91.4% de la variabilidad de los ingresos: que respresenta un muy buen ajuste.Como es mayor al resto de los otros dos modelos, esto indica que es un modelo que hará mejores predicciones.
- RMSE bajo (32k) comparado con los demás modelos, es decir, se presentan errores mucho más pequeños.
- Random Forest maneja muy bien relaciones no lineales y complejas interacciones entre variables, lo que explica su gran desempeño.

3.Gradient Boosting Regressor

- Explica solo el 19.1% de la variabilidad, es decir, un ajuste pobre.
- RMSE alto ($\approx 98k$), algo similar con lo presentado en la regresión lineal.
- Puede que se tenga una gran dispersión entre los salarios y no se captura bien la distribución. Una posible mejora para este modelo sería ajustar los hiperparámetros.